

Eksploracja danych

REGUŁY ASOCJACYJNE

Wojciech Waloszek

wowal@eti.pg.gda.pl

Teresa Zawadzka

tegra@eti.pg.gda.pl

Katedra Inżynierii Oprogramowania

Wydział Elektroniki, Telekomunikacji i Informatyki

Politechnika Gdańska



Budowa reguł asocjacyjnych

- Przy budowie reguł asocjacyjnych nie mamy wyróżnionego atrybutu decyzyjnego,
- Próbujemy uchwycić różne zależności między atrybutami bez wyróżniania żadnego z nich,
- Naiwne podejście mogłoby polegać na wygenerowaniu klasyfikatora decyzyjnego dla każdego z atrybutów – jest ono jednak skrajnie nieefektywne

Algorytm Apriori

- Algorytm działa jedynie na atrybutach nominalnych,
- Dla generowanych reguł ustalamy progi pokrycia i poprawności (s_{min} i a_{min}),
- Algorytm ten buduje reguły tworząc testy złożone,
- Na początek brane pod uwagę jest jedynie pokrycie testu, które musi przekraczać ustalony próg minimalny

Apriori – przykład

- Próg pokrycia ustalamy na $s_{min}=2 / 9$,
- Najpierw bierzemy pod uwagę testy proste:

S.C.=S

S.C.=M

Wykształcenie=podstawowe

Wykształcenie=średnie

Wykształcenie=wyższe

Sam.=tak

Sam.=nie

Z.K.=tak

Z.K.=nie

Obliczanie pokrycia testu

S.C.	D.O.R.	Wiek	Wykształcenie	Sam.	Z.K.
S	800	32	wyższe	tak	tak
S	1200	35	średnie	tak	tak
S	700	26	podstawowe	nie	nie
M	600	45	wyższe	nie	tak
M	650	38	średnie	tak	tak
S	900	28	wyższe	nie	nie
S	1100	65	średnie	tak	nie
M	500	22	średnie	nie	nie
S	800	43	podstawowe	tak	nie

$$S.C. = S$$

$$\text{Pokrycie: } s = 6 / 9$$

Apriori – testy proste

- Otrzymujemy następujące pokrycia:

	s
S.C.=S	6/9
S.C.=M	3/9
Wykształcenie=podstawowe	2/9
Wykształcenie=średnie	4/9
Wykształcenie=wyższe	3/9
Sam.=tak	5/9
Sam.=nie	4/9
Z.K.=tak	4/9
Z.K.=nie	5/9

Wszystkie testy proste przekraczają próg pokrycia i mogą być wykorzystane do budowy testów złożonych

Apriori – testy złożone

- Testy podwójne budujemy z testów pojedynczych z poprzedniego kroku (oba składowe testy pojedyncze muszą mieć minimalne pokrycie),
- Pary budujemy według zasady każdy-z-każdym (oprócz odrzuconych):

`S.C.=S and Wykształcenie=podstawowe`

`S.C.=S and Wykształcenie=średnie`

`S.C.=S and Wykształcenie=wyższe`

`S.C.=S and Sam.=tak`

`...`

Apriori – testy złożone (2)

- Następnie badamy pokrycia testów:

	s
S.C.=S and Wykształcenie=podstawowe	2/9
S.C.=S and Wykształcenie=średnie	2/9
S.C.=S and Wykształcenie=wyższe	2/9
...	
S.C.=M and Wykształcenie=wyższe	1/9
...	

Spośród 30 testów złożonych kryterium pokrycia spełnia 19

Apriori – generacja reguł

- Otrzymaliśmy 19 testów złożonych spełniających warunek minimalnego pokrycia,
- Z każdego testu możemy spróbować wygenerować reguły; dla testu:

S.C.=S and Wykształcenie=podstawowe

mogą to być:

if S.C.=S then Wykształcenie=podstawowe

if Wykształcenie=podstawowe then S.C.=S

Apriori – generacja reguł (2)

- Reguły akceptujemy tylko jeżeli przekraczają one próg poprawności (ustalmy $a_{min}=1$):

	a
if S.C.=S then Wykształcenie=podstawowe	2/6
if Wykształcenie=podstawowe then S.C.=S	2/2

Kryterium poprawności spełnia tylko jedna z wygenerowanych reguł

Apriori – generacja reguł (3)

- Z 19 testów podwójnych możemy wygenerować tylko 2 reguły spełniające progi poprawności:

`if Wykształcenie=podstawowe then S.C.=S`

`if Wykształcenie=podstawowe then Z.K.=nie`

- Po wygenerowaniu tych reguł możemy przystąpić do generacji testów potrójnych

Apriori – testy potrójne

- Testy potrójne budujemy z testów podwójnych z poprzedniego kroku (wszystkie składowe testy podwójne muszą mieć minimalne pokrycie):

S.C.=S and Sam.=nie and Z.K.=tak

na pewno nie spełnia kryterium pokrycia,
bo nie spełnia go test podwójny:

Sam.=nie and Z.K.=tak

Apriori – testy potrójne (2)

- Kryterium pokrycia spełniają następujące testy potrójne:

Wykształcenie=wyższe and Sam.=tak and Z.K.=tak

S.C.=S and Sam.=nie and Z.K.=nie

S.C.=S and Sam.=tak and Z.K.=nie

S.C.=S and Sam.=tak and Z.K.=tak

S.C.=S and Wykształcenie=wyższe and Sam.=tak

S.C.=S and Wykształcenie=podstawowe and Z.K.=tak

- Dla każdego testu generowane są reguły, dla których sprawdzane jest kryterium poprawności

Apriori – przykład

- Dla testu:

Wykształcenie=wyższe and Sam.=tak and Z.K.=tak

generowane są następujące reguły:

```
if Wykształcenie=wyższe then Sam.=tak and Z.K.=tak
if Sam.=tak then Wykształcenie=wyższe and Z.K.=tak
if Z.K.=tak then Wykształcenie=wyższe and Sam.=tak
if Wykształcenie=wyższe and Sam.=tak then Z.K.=tak
if Wykształcenie=wyższe and Z.K.=tak then Sam.=tak
if Sam.=tak and Z.K.=tak then Wykształcenie=wyższe
```

Tylko jedna spełnia kryterium poprawności

Apriori – generacja reguł

- Z 6 testów potrójnych generujemy 8 reguł spełniających próg poprawności:

```
if Wykształcenie=wyższe then Sam.=tak and Z.K.=tak
if S.C.=S and Sam.=nie then Z.K.=nie
if Sam.=tak and Z.K.=nie then S.C.=S
if S.C.=S and Z.K.=tak then Sam.=tak
if S.C.=S and Wykształcenie=wyższe then Sam.=tak
if Wykształcenie=postawowe then S.C.=S and Z.K.=nie
if S.C.=S and Wykształcenie=postawowe then Z.K.=nie
if Wykształcenie=postawowe and Z.K.=nie then S.C.=S
```

- Po wygenerowaniu tych reguł możemy przystąpić do generacji testów poczwórnych

Apriori – testy poczwórne

- Testy poczwórne budujemy z testów potrójnych z poprzedniego kroku (wszystkie składowe testy podwójne muszą mieć minimalne pokrycie),
- W podanym przykładzie nie ma testów poczwórnych spełniających warunek minimalnego pokrycia,
- Oznacza to, że algorytm Apriori kończy pracę

Algorytm Apriori

Wejście: s_{min} – próg pokrycia,
 a_{min} – próg poprawności,
 P – zbiór przykładów

Wyjście: R – zbiór reguł

1. $n := 1, R := \{\}$
2. Generuj zbiór testów pojedynczych T_1
3. Eliminuj testy o pokryciu mniejszym od s_{min}
4. Dopóki T_n jest niepusty wykonuj:
5. $n := n + 1$
6. Generuj zbiór testów n -krotnych T_n
7. Eliminuj z T_n testy o pokryciu mniejszym od s_{min}
8. Dla każdego testu t z T_n :
9. Generuj zbiór R_t reguł dla testu t
10. Eliminuj z R_t reguły o poprawności mniejszej od a_{min}
11. $R := R \cup R_t$
12. Koniec pętli wewnętrznej
13. Koniec pętli zewnętrznej

Apriori – drugi przykład

- Prześledźmy jeszcze działanie algorytmu dla $s_{min} = 4/9$ i $a_{min} = 0,8$

Apriori – drugi przykład (2)

- Dla testów prostych otrzymujemy następujące pokrycia:

	s
S.C.=S	6/9
S.C.=M	3/9
Wykształcenie=podstawowe	2/9
Wykształcenie=średnie	4/9
Wykształcenie=wyższe	3/9
Sam.=tak	5/9
Sam.=nie	4/9
Z.K.=tak	4/9
Z.K.=nie	5/9

Testy niespełniające kryterium pokrycia możemy wyeliminować.

Apriori – drugi przykład (3)

- Testy podwójne budujemy z testów pojedynczych z poprzedniego kroku (oba składowe testy pojedyncze muszą mieć minimalne pokrycie),
- Po odrzuceniu testów niespełniających kryterium pokrycia otrzymujemy dwa testy podwójne:

S.C.=S and Sam.=tak

S.C.=S and Z.K.=nie

Apriori – drugi przykład (4)

- Z testów podwójnych możemy wygenerować 2 reguły spełniające progi poprawności:

`if Z.K.=nie then S.C.=S`

`if Sam.=tak then S.C.=S`

- Po wygenerowaniu tych reguł możemy przystąpić do generacji testów potrójnych

Apriori – drugi przykład (5)

- Żaden z testów potrójnych nie spełnia kryterium minimalnego pokrycia, zatem ostateczny wynik pracy algorytmu to:

`if Z.K.=nie then S.C.=S`

`if Sam.=tak then S.C.=S`

Apriori – komentarz

- Apriori w większości przypadków pozwala stosunkowo szybko (mimo teoretycznie wykładniczej złożoności) wygenerować reguły asocjacyjne,
- Liczba generowanych reguł jest zazwyczaj bardzo duża, zatem zalecane jest rozpoczęcie pracy do wysokiego progu pokrycia i redukovanie go w trakcie analizy