

Eksploracja danych

KLASYFIKACJA I REGRESJA cz. 1

Wojciech Waloszek

wowal@eti.pg.gda.pl

Teresa Zawadzka

tegra@eti.pg.gda.pl

Katedra Inżynierii Oprogramowania



Wydział Elektroniki, Telekomunikacji i Informatyki

Politechnika Gdańska



Tworzenie modelu danych


Proces eksploracji danych można rozumieć jako dopasowywanie modelu do danych




Budowa drzew decyzyjnych

- Drzewa decyzyjne to najpopularniejsza forma klasyfikatorów,
- Najczęściej budowane są metodą zstępującą, na zasadzie podejścia naturalnego dla drzew podejścia divide-and-conquer

Przykład drzewa decyzyjnego



Przykład drzewa decyzyjnego




Budowa drzewa

S.C.	D.O.R.	Wiek	Wykształcenie	Sam.	Z.K.
S	800	32	wyższe	tak	tak
S	1200	35	średnie	tak	tak
S	700	26	podstawowe	nie	nie
M	600	45	wyższe	nie	tak
M	650	38	średnie	tak	tak
S	900	28	wyższe	nie	nie
S	1100	65	średnie	tak	nie
M	500	22	średnie	nie	nie
S	800	43	podstawowe	tak	nie

1. Mamy wyróżniony atrybut decyzyjny, wyznaczający *klasy*
2. Na każdym poziomie drzewa wybieramy jeden z pozostałych atrybutów, najlepszy pod kątem dyskryminowania klas
3. Rozpoczynamy od pustego drzewa wyznaczając korzeń

Dobór atrybutu



Czy podział pod względem wartości atrybutu S.C. jest korzystny?

I w jakiej mierze?

Miara jakości podziału

- Jedną z miar jakości podziału jest *przyrost zawartości informacji*
- Przyrost zawartości informacji jest określony jako różnica zawartości *informacji* w dzielonym zbiorze przykładów a *entropią* zastosowanego podziału (*testu*).

Miara jakości podziału – wzory

$$I(P) = \sum_{d \in C} - \frac{|P^d|}{|P|} \log_2 \frac{|P^d|}{|P|}$$

$$E_t(P) = \sum_{r \in R_t} \frac{|P_{tr}|}{|P|} I(P_{tr})$$

$I(P)$ – zawartość informacyjna zbioru przykładów P

C – zbiór klas wyznaczony przez atrybut decyzyjny

P^d – podzbiór tych przykładów ze zbioru P , które należą do klasy d

$E_t(P)$ – entropia testu t dla zbioru przykładów P


R_t – zbiór możliwych wyników testu t

P_{tr} – podzbiór tych przykładów ze zbioru P , które dają dla testu t wynik r

Dobór atrybutu - przykład

4 x tak 5 x nie

$$I(P) = -\frac{4}{9} \log_2 \frac{4}{9} - \frac{5}{9} \log_2 \frac{5}{9} \approx 0,99$$



$t = "S.C. = ?"$
 $R_t = \{S, M\}$

$$I(P_{S.C.=S}) = -\frac{2}{6} \log_2 \frac{2}{6} - \frac{4}{6} \log_2 \frac{4}{6} \approx 0,92$$

$$I(P_{S.C.=M}) = -\frac{2}{3} \log_2 \frac{2}{3} - \frac{1}{3} \log_2 \frac{1}{3} \approx 0,92$$

$$E_t(P) \approx \frac{6}{9} \cdot 0,92 + \frac{3}{9} \cdot 0,92 \approx 0,92$$

$$g_t(P) \approx 0,99 - 0,92 \approx 0,07$$

Dobór atrybutu – przykład (2)

4 x tak 5 x nie

$$I(P) = -\frac{4}{9} \log_2 \frac{4}{9} - \frac{5}{9} \log_2 \frac{5}{9} \approx 0,99$$

Wykształcenie

$t = \text{"Wykształcenie = ?"}$

$R_t = \{ \text{wyższe, średnie, podstawowe} \}$

podstawowe

wyższe

średnie

2 x tak 1 x nie

2 x tak 2 x nie

0 x tak 2 x nie

$$I(P_{\text{Wykształcenie=wyższe}}) \approx 0,92$$

$$I(P_{\text{Wykształcenie=średnie}}) = 1$$

$$I(P_{\text{Wykształcenie=podstawowe}}) = 0$$


$$E_t(P) \approx \frac{3}{9} \cdot 0,92 + \frac{4}{9} \cdot 1 + \frac{2}{9} \cdot 0 \approx 0,75$$

$$g_t(P) \approx 0,99 - 0,75 \approx 0,24$$

Dobór atrybutu – przykład (3)

4 x tak 5 x nie

$$I(P) = -\frac{4}{9} \log_2 \frac{4}{9} - \frac{5}{9} \log_2 \frac{5}{9} \approx 0,99$$



$t = "Sam. = ?"$
 $R_t = \{tak, nie\}$

$$I(P_{Sam.=tak}) \approx 0,97$$


$$I(P_{Sam.=nie}) \approx 0,81$$

$$E_t(P) \approx \frac{5}{9} \cdot 0,97 + \frac{4}{9} \cdot 0,81 \approx 0,90$$

$$g_t(P) \approx 0,99 - 0,90 \approx 0,1$$

Dobór atrybutu – przykład (4)

- Najwyższy zysk informacji (0,24) osiągnął atrybut *Wykształcenie* i on zostaje zapisany w korzeniu drzewa decyzyjnego




Divide-and-conquer

S.C.	D.O.R.	Wiek	Wykształcenie	Sam.	Z.K.
S	800	32	wyższe	tak	tak
S	1200	35	średnie	tak	tak
S	700	26	podstawowe	nie	nie
M	600	45	wyższe	nie	tak
M	650	38	średnie	tak	tak
S	900	28	wyższe	nie	nie
S	1100	65	średnie	tak	nie
M	500	22	średnie	nie	nie
S	800	43	podstawowe	tak	nie


1. Zbiór przykładów został podzielony na trzy części
2. Dla każdej z części może zostać zastosowany ten sam algorytm dalszego działania

Dalsza budowa drzewa


- Wzdłuż prawej gałęzi drzewa nie trzeba już rozbudowywać



Dalsza budowa drzewa (2)



Drzewo jak dotąd



Atrybuty numeryczne


- Do tej pory zakładaliśmy użycie tylko atrybutów nominalnych,
- W trakcie budowy drzewa wykorzystywane mogą być też atrybuty numeryczne,
- Tutaj przedstawimy zasadę podziału binarnego minimalizującego entropię

Atrybuty numeryczne (2)

S.C.	D.O.R.	Wiek	Wykształcenie	Sam.	Z.K.
S	800	32	wyższe	tak	tak
S	1200	35	średnie	tak	tak
S	700	26	podstawowe	nie	nie
M	600	45	wyższe	nie	tak
M	650	38	średnie	tak	tak
S	900	28	wyższe	nie	nie
S	1100	65	średnie	tak	nie
M	500	22	średnie	nie	nie
S	800	43	podstawowe	tak	nie

1. W trakcie budowy drzewa doszliśmy do wydzielenia 3 przykładów
2. W tym miejscu drzewa najlepiej zastosować podział względem wartości atrybutu numerycznego (wcześniej oczywiście takie podziały też były rozważane ale odrzucane)

Dalsza budowa drzewa (2)



$$I(P) \approx 0,92$$

Wiek:	35	38	65
Z.K.:	tak	tak	nie

$t = \text{"Wiek"} \leq x$


$$R_t = \{ \leq x, > x \}$$

$$I(P_{\text{Wiek} \leq x}) \approx 0 \qquad I(P_{\text{Wiek} > x}) \approx 1$$

$$E_t(P) \approx \frac{1}{3} \cdot 0 + \frac{2}{3} \cdot 1 \approx 0,67$$

$$g_t(P) \approx 0,92 - 0,67 \approx 0,25$$

Dalsza budowa drzewa (3)



$$I(P) \approx 0,92$$

Wiek:	35	38	65
Z.K.:	tak	tak	nie

$t = \text{"Wiek} \leq x"$


$$R_t = \{ \leq x, > x \}$$

$$I(P_{\text{Wiek} \leq x}) \approx 0 \quad I(P_{\text{Wiek} > x}) \approx 0$$

$$E_t(P) \approx \frac{1}{3} \cdot 0 + \frac{2}{3} \cdot 0 = 0$$

$$g_t(P) \approx 0,92 - 0 \approx 0,92$$

Przykład drzewa decyzyjnego



Algorytm budowy drzew decyzyjnych

- Budowa drzewa polega na doborze najlepszego atrybutu nominalnego lub najlepszego podziału binarnego atrybutu numerycznego, powtarzanym iteracyjnie,
- „Najlepszy” atrybut dobierany jest według pewnej funkcji oceny (tu: entropia)

Przycinanie

- Przycinanie polega na zastąpieniu poddrzewa liściem,
- Przycinanie ma na celu uogólnienie wyników i zapobieżenie błędowi nadmiernego dopasowania,
- Stosuje się różne kryteria przycinania:
 - przycinanie *apriori* (w trakcie pracy zasadniczego algorytmu), gdy węzeł drzewa pokrywa zbyt małą liczbę przykładów,
 - przycinanie *aposteriori* (po pracy zasadniczego algorytmu), najczęściej *wstępująca* w wyniku badania rezultatów klasyfikacji na *zbiorze testującym*,
- W wyniku przycinania liście stają się *węzłami probabilistycznymi*

Brakujące wartości atrybutów

S.C.	D.O.R.	Wiek	Wykształcenie	Sam.	Z.K.
S	800	32	wyższe	tak	tak
S	1200	35	średnie	tak	tak
S	700	26	podstawowe	nie	nie
M	600	45	wyższe	nie	tak
M	650	38	średnie	tak	tak
S	900	28	wyższe	nie	nie
S	1100	65	średnie	tak	nie
M	500	22	średnie	nie	nie
S	800	43	podstawowe	tak	nie
M	750	47	?	nie	nie

Zakładamy, że mamy dodatkowy przykład o nieznannej wartości atrybutu *Wykształcenie*

Brakujące wartości atrybutów (2)

4 x tak 6 x nie

$$I(P) \approx 0,92$$

$t = \text{"Wykształcenie" = ?}$

$R_t = \{\text{wyższe, średnie, podstawowe}\}$

podstawowe

Wykształcenie

wyższe

średnie

2 x tak (1 + 3/9) x nie

2 x tak (2 + 4/9) x nie

0 x tak (2 + 2/9) x nie

$$I(P_{\text{Wykształcenie=wyższe}}) \approx 0,97$$

$$I(P_{\text{Wykształcenie=średnie}}) = 0,99$$

$$I(P_{\text{Wykształcenie=podstawowe}}) = 0$$

$$E_t(P) \approx \frac{3+3/9}{10} \cdot 0,97 + \frac{4+4/9}{10} \cdot 0,99 + \frac{2+2/9}{10} \cdot 0 \approx 0,76$$

$$g_t(P) \approx 0,92 - 0,76 \approx 0,16$$

Algorytm budowy drzew decyzyjnych (~C4.5):

1. Zadanie: predykcja (klasyfikacja)
2. Struktura modelu: drzewo
3. Funkcja oceny jakości: przyrost zawartości informacyjnej
4. Metody przeszukiwania: zachłanna, divide-and-conquer
5. Dodatkowe założenia:

Obsługa brakujących wartości atrybutów metodą podziału przykładu

Obsługa atrybutów numerycznych metodą podziału binarnego minimalizującego entropię

Przycinanie drzewa metodą wstępującą aposteriori (walidacja krzyżowa)

Algorytm budowy drzew decyzyjnych (~C4.5):

1. Zadanie: predykcja (klasyfikacja)
2. Struktura modelu: drzewo
3. Funkcja oceny jakości: przyrost zawartości informacyjnej
4. Metody przeszukiwania: zachłanna, divide-and-conquer
5. Dodatkowe założenia:

Obsługa brakujących wartości atrybutów metodą podziału przykładu

Obsługa atrybutów numerycznych metodą podziału binarnego minimalizującego entropię

Przycinanie drzewa metodą wstępującą aposteriori (walidacja krzyżowa)

Algorytm budowy drzew decyzyjnych (~C4.5):

1. Zadanie: predykcja (klasyfikacja)
2. Struktura modelu: drzewo
3. Funkcja oceny jakości: przyrost zawartości informacyjnej
4. Metody przeszukiwania: zachłanna, divide-and-conquer
5. Dodatkowe założenia:

Obsługa brakujących wartości atrybutów metodą podziału przykładu

Obsługa atrybutów numerycznych metodą podziału binarnego minimalizującego entropię

Przycinanie drzewa metodą wstępującą aposteriori (walidacja krzyżowa)