

Eksploracja danych

KLASYFIKACJA I REGRESJA cz. 3

Wojciech Waloszek

wowal@eti.pg.gda.pl

Teresa Zawadzka

tegra@eti.pg.gda.pl

Katedra Inżynierii Oprogramowania

Wydział Elektroniki, Telekomunikacji i Informatyki

Politechnika Gdańska



Naiwny klasyfikator Bayesa

- Naiwny klasyfikator Bayesa (NKB) wykorzystuje wprost pojęcie prawdopodobieństwa warunkowego,
- Jest to prosty klasyfikator, ale bardzo często można dzięki niemu uzyskać „zawstydzająco” dobre rezultaty predykcji

Zasada działania NKB

S.C.	D.O.R.	Wiek	Wykształcenie	Sam.	Z.K.
S	800	32	wyższe	tak	tak
S	1200	35	średnie	tak	tak
S	700	26	podstawowe	nie	nie
M	600	45	wyższe	nie	tak
M	650	38	średnie	tak	tak
S	900	28	wyższe	nie	nie
S	1100	65	średnie	tak	nie
M	500	22	średnie	nie	nie
S	800	43	podstawowe	tak	nie

1. Mamy wyróżniony atrybut decyzyjny, wyznaczający *klasy*
2. Próbujemy stwierdzić, co o przynależności do konkretnych klas możemy powiedzieć na podstawie wartości konkretnych atrybutów.
3. Każdy atrybut oceniamy oddzielnie.

Klasyfikacja nowego przykładu

- Załóżmy, że chcemy sklasyfikować nowy przykład:

M	1200	30	wyższe	tak	?
---	------	----	--------	-----	---

- Zadajemy sobie pytania:
 - Co możemy powiedzieć o przynależności do złotych klientów na podstawie tego, że $S.C. = M$?
 - Co możemy powiedzieć o przynależności do złotych klientów na podstawie tego, że Wykształcenie = wyższe?
 - itd.

S.C. = M?

S.C.	D.O.R.	Wiek	Wykształcenie	Sam.	Z.K.
S	800	32	wyższe	tak	tak
S	1200	35	średnie	tak	tak
S	700	26	podstawowe	nie	nie
M	600	45	wyższe	nie	tak
M	650	38	średnie	tak	tak
S	900	28	wyższe	nie	nie
S	1100	65	średnie	tak	nie
M	500	22	średnie	nie	nie
S	800	43	podstawowe	tak	nie

Dla złotych klientów, klienci „małżeńscy” stanowią **2/4** populacji.

Dla nie-złotych klientów, klienci „małżeńscy” stanowią **1/5** populacji.

Wykształcenie = wyższe?

S.C.	D.O.R.	Wiek	Wykształcenie	Sam.	Z.K.
S	800	32	wyższe	tak	tak
S	1200	35	średnie	tak	tak
S	700	26	podstawowe	nie	nie
M	600	45	wyższe	nie	tak
M	650	38	średnie	tak	tak
S	900	28	wyższe	nie	nie
S	1100	65	średnie	tak	nie
M	500	22	średnie	nie	nie
S	800	43	podstawowe	tak	nie

Dla złotych klientów, klienci z wykształceniem wyższym stanowią **2/4** populacji.

Dla nie-złotych klientów, klienci z wykształceniem wyższym stanowią **1/5** populacji.

Sam. = tak?

S.C.	D.O.R.	Wiek	Wykształcenie	Sam.	Z.K.
S	800	32	wyższe	tak	tak
S	1200	35	średnie	tak	tak
S	700	26	podstawowe	nie	nie
M	600	45	wyższe	nie	tak
M	650	38	średnie	tak	tak
S	900	28	wyższe	nie	nie
S	1100	65	średnie	tak	nie
M	500	22	średnie	nie	nie
S	800	43	podstawowe	tak	nie

Dla złotych klientów, klienci z samochodem stanowią **3/4** populacji.

Dla nie-złotych klientów, klienci z samochodem stanowią **2/5** populacji.

Decyzja!

Do podjęcia decyzji potrzebujemy jeszcze względnej liczebności klas: **złoci klienci** stanowią **4/9** zbioru przykładów, a **nie-złoci klienci** stanowią **5/9** zbioru.

M	1200	30	wyższe	tak	?
---	------	----	--------	-----	---

Na „tak”: $2/4 \cdot 2/4 \cdot 3/4 \cdot 4/9 \approx 0,083$

Na „nie”: $1/5 \cdot 1/5 \cdot 2/5 \cdot 5/9 \approx 0,009$

Decyzja: **Z.K. = tak**

Decyzja!

Do podjęcia decyzji potrzebujemy jeszcze względnej liczebności klas: **złoci klienci** stanowią **4/9** zbioru przykładów, a **nie-złoci klienci** stanowią **5/9** zbioru.

M	1200	30	wyższe	tak	?
---	------	----	--------	-----	---

Na „tak”: $2/4 \cdot 2/4 \cdot 3/4 \cdot 4/9 \approx 0,083$

Na „nie”: $1/5 \cdot 1/5 \cdot 2/5 \cdot 5/9 \approx 0,009$

Decyzja: **Z.K. = tak**

Ale co za tym stoi?

Tak naprawdę, mówiąc formalnie, chcemy estymować prawdopodobieństwo dwóch zdarzeń:

$$P(Z.K = \text{tak} \mid E)$$

$$P(Z.K = \text{nie} \mid E)$$

Przy czym E jest złożonym zdarzeniem postaci:
S.C. = M, Wykształcenie = wyższe, Sam. = tak

Decyzja zapada poprzez porównanie wartości dwóch estymatorów prawdopodobieństw.

Prawo Bayesa

Do zbudowania estymatorów wykorzystujemy tzw. prawo Bayesa:

$$P(H|E) = \frac{P(E|H) \cdot P(H)}{P(E)}$$

Ponieważ interesuje nas jedynie porównanie wartości dwóch prawdopodobieństw skupiamy się na liczniku, porównując:

$$P(Z.K = \text{tak}|E) \cdot P(E) = P(E|Z.K = \text{tak}) \cdot P(Z.K = \text{tak})$$

$$P(Z.K = \text{nie}|E) \cdot P(E) = P(E|Z.K = \text{nie}) \cdot P(Z.K = \text{nie})$$

Naiwność klasyfikatora Bayesa

Prawdopodobieństwo warunkowe zdarzenia złożonego E , stanowiącego złożenie **niezależnych** zdarzeń prostych $E_1, E_2 \dots$ można wyrazić jako:

$$P(E|H) = P(E_1|H) \cdot P(E_2|H) \cdot \dots$$

Stąd otrzymujemy ostatni element wzoru:

$$P(E|Z.K = \text{tak}) = P(\text{S.C.} = M \mid Z.K = \text{tak}) \cdot \\ P(\text{Wykształcenie} = \text{wyższe} \mid Z.K = \text{tak}) \cdot \\ P(\text{Sam.} = \text{tak} \mid Z.K. = \text{tak})$$

$$P(E|Z.K = \text{nie}) = P(\text{S.C.} = M \mid Z.K = \text{nie}) \cdot \\ P(\text{Wykształcenie} = \text{wyższe} \mid Z.K = \text{nie}) \cdot \\ P(\text{Sam.} = \text{tak} \mid Z.K. = \text{nie})$$

Przyjmujemy tu jednak „naiwnie”, że np. posiadanie samochodu nie ma nic wspólnego z posiadaniem wyższego wykształcenia.

Atrybuty numeryczne

- W klasycznej wersji NKB obsługuje jedynie atrybuty nominalne.
- Rozszerzenie klasyfikatora polega na doborze metody wyznaczenia estymatora $P(A = x|H)$ dla atrybutów numerycznych A ,
- Można to zrobić poprzez przyjęcie konkretnej postaci rozkładu wartości danego atrybutu, najczęściej przyjmuje się rozkład normalny z estymowanymi parametrami rozkładu:

$$P(A = x|H) = \frac{1}{\sqrt{2\pi} \cdot \sigma_H} e^{-\frac{(x - \mu_H)^2}{2\sigma_H^2}}$$

Atrybuty numeryczne

- W klasycznej wersji NKB obsługuje jedynie atrybuty nominalne.
- Rozszerzenie klasyfikatora polega na doborze metody wyznaczenia estymatora $P(A = x|H)$ dla atrybutów numerycznych A ,
- Można to zrobić poprzez przyjęcie konkretnej postaci rozkładu wartości danego atrybutu, najczęściej przyjmuje się rozkład normalny z estymowanymi parametrami rozkładu:

$$P(A = x|H) = \frac{1}{\sqrt{2\pi} \cdot \sigma_H} e^{-\frac{(x - \mu_H)^2}{2\sigma_H^2}}$$

Parametry rozkładu

S.C.	D.O.R.	Wiek	Wykształcenie	Sam.	Z.K.
S	800	32	wyższe	tak	tak
S	1200	35	średnie	tak	tak
S	700	26	podstawowe	nie	nie
M	600	45	wyższe	nie	tak
M	650	38	średnie	tak	tak
S	900	28	wyższe	nie	nie
S	1100	65	średnie	tak	nie
M	500	22	średnie	nie	nie
S	800	43	podstawowe	tak	nie

Dla złotych klientów, $\mu_{DOR} = 812,5$; $\sigma_{DOR} = 271,95$; $\mu_{Wiek} = 37,5$; $\sigma_{Wiek} = 5,57$.

Dla nie-złotych klientów, $\mu_{DOR} = 800$; $\sigma_{DOR} = 223,61$; $\mu_{Wiek} = 36,8$; $\sigma_{Wiek} = 17,66$.

Decyzja (2)!

Tym razem w decyzji uwzględniamy jeszcze wartości atrybutów numerycznych.

M	1200	30	wyższe	tak	?
---	------	----	--------	-----	---

Na „tak”: $2/4 \cdot 0,0005 \cdot 0,029 \cdot 2/4 \cdot 3/4 \cdot \mathbf{4/9} \approx 1,2 \cdot 10^{-6}$

Na „nie”: $1/5 \cdot 0,0003 \cdot 0,021 \cdot 1/5 \cdot 2/5 \cdot \mathbf{5/9} \approx 5,6 \cdot 10^{-8}$

Decyzja: **Z.K. = tak**

Inne rozszerzenia NKB

- NKB w sposób naturalny obsługuje brakujące wartości atrybutów (usuwamy ze wzoru odpowiednie prawdopodobieństwo).
- NKB można rozszerzać poprzez dodawanie „drobnych” wartości prawdopodobieństw do poszczególnych estymatorów, co zapobiega estymacji zerowych prawdopodobieństw.
- Atrybuty numeryczne można obsługiwać, dobierając inne rozkłady, a także poprzez przeprowadzenie dyskretyzacji.

Inne rozszerzenia NKB

- NKB w sposób naturalny obsługuje brakujące wartości atrybutów (usuwamy ze wzoru odpowiednie prawdopodobieństwo).
- NKB można rozszerzać poprzez dodawanie „drobnych” wartości prawdopodobieństw do poszczególnych estymatorów, co zapobiega estymacji zerowych prawdopodobieństw.
- Atrybuty numeryczne można obsługiwać, dobierając inne rozkłady, a także poprzez przeprowadzenie dyskretyzacji.

NKB – podsumowanie

Naiwny klasyfikator Bayesa:

1. Zadanie: predykcja (klasyfikacja)
2. Struktura modelu: Bayesowski model prawdopodobieństw apriori
3. Funkcja oceny jakości: brak
4. Metody przeszukiwania: jednoprzebiegowa estymacja prawdopodobieństw
5. Dodatkowe założenia:
Obsługa atrybutów numerycznych poprzez założenie ustalonego rozkładu

Regresja

- W przypadku przewidywania wartości numerycznych używamy pojęcia regresji,
- Najbardziej popularne metody predykcji numerycznej bazują właśnie na metodach regresji,
- Metody regresji mogą także być użyte do klasyfikacji


Regresja liniowa

- Regresja liniowa polega na odnajdywaniu parametrów równania liniowego uzależniającego wartość jednego atrybutu od pozostałych:

$$X = w_0 + w_1 \cdot a_1 + w_2 \cdot a_2 + \dots$$

- Wagi poszczególnych atrybutów (w_i) dobiera się, minimalizując pewną *funkcję błędu*, najczęściej tzw. błąd średniokwadratowy

Wiek a D.O.R.



$$\text{D.O.R.} = 513 + 7,86 \cdot \text{Wiek}$$

Atrybuty nominalne a regresja

- Regresja liniowa w klasycznej postaci pozwala na obsługę wyłącznie atrybutów numerycznych.
- Atrybuty nominalne można zamienić na zbiór atrybutów ciągłych wg następującej recepty:
 - sortujemy wartości atrybutu a względem średniej wartości atrybutu przewidywanego,
 - tworzymy $n - 1$ atrybutów $a.i$, gdzie n to liczba możliwych wartości atrybutu nominalnego a ,
 - atrybut $a.i$ przyjmuje wartość 0 gdy a ma wartość najwyższą i -tą według przeprowadzonego sortowania

Przykład (wykształcenie)

S.C.	D.O.R.	Wiek	Wykształcenie	Sam.	Z.K.
S	800	32	wyższe	tak	tak
S	1200	35	średnie	tak	tak
S	700	26	podstawowe	nie	nie
M	600	45	wyższe	nie	tak
M	650	38	średnie	tak	tak
S	900	28	wyższe	nie	nie
S	1100	65	średnie	tak	nie
M	500	22	średnie	nie	nie
S	800	43	podstawowe	tak	nie

Posortowane wartości, podstawowe (750), wyższe (766,67), średnie (862,5).

podstawowe → Wykształcenie-1 = 0, Wykształcenie-2 = 0

wyższe → Wykształcenie-1 = 1, Wykształcenie-2 = 0

średnie → Wykształcenie-1 = 1, Wykształcenie-2 = 1


Regresja liniowa – podsumowanie

Regresja liniowa:

1. Zadanie: predykcja numeryczna
2. Struktura modelu: wektor wag atrybutów
3. Funkcja oceny jakości: funkcja błędu (średniokwadratowego)
4. Metody przeszukiwania: wyliczana bezpośrednio lub za pomocą dowolnej heurystycznej metody minimalizacji
5. Dodatkowe założenia:




Obsługa atrybutów nominalnych poprzez zamianę ich na serię atrybutów numerycznych

Rozszerzone metody regresji – wyższe stopnie



Wielomian trzeciego stopnia

Rozszerzone metody regresji – fragmenty



Segmentowa regresja liniowa z wygładzaniem


Drzewa predykcji numerycznej

- Drzewa predykcji numerycznej rozwijają pomysł regresji liniowej dokonywanej segmentami,
- Drzewa dokonują podziału przykładów względem wartości pozostałych atrybutów, tak aby w liściach pozostawały zbliżone wartości atrybutu, którego wartość przewidujemy,
- Drzewa mogą mieć postać *drzewa regresji* (gdy w liściach mamy wartości) lub *drzewa modelu*, gdy w liściach zawarte są modele regresji liniowej

Drzewa predykcji numerycznej

- Drzewa predykcji numerycznej rozwijają pomysł regresji liniowej dokonywanej segmentami,
- Drzewa dokonują podziału przykładów względem wartości pozostałych atrybutów, tak aby w liściach pozostawały zbliżone wartości atrybutu, którego wartość przewidujemy,
- Drzewa mogą mieć postać *drzewa regresji* (gdy w liściach mamy wartości) lub *drzewa modelu*, gdy w liściach zawarte są modele regresji liniowej

Drzewo modelu



$$\begin{aligned} \text{D.O.R.} = & 340.28 * \text{S.C.-1} + \\ & + 187.5 * \text{Wykształcenie-2} + \\ & + 458.33 \end{aligned}$$

$$\begin{aligned} \text{D.O.R.} = & 291.67 * \text{S.C.-2} + \\ & + 260.71 * \text{Wykształcenie-2} + \\ & + 538.09 \end{aligned}$$

Dobór najlepszego atrybutu

- Dobór atrybutu odbywa się na zasadzie minimalizacji odchylenia standardowego:

$$SDR = \sigma(P) - \sum_i ((|P^i|/|P|) \cdot \sigma(P^i))$$

- Testy dla wartości numerycznych są binarne z wartością minimalizującą SDR,
- Atrybuty nominalne obsługiwane są zgodnie ze sposobem opisanym wcześniej dla regresji

Dobór najlepszego atrybutu

- Dobór atrybutu odbywa się na zasadzie minimalizacji odchylenia standardowego:

$$\text{SDR} = \sigma(P) - \sum_i ((|P^i|/|P|) \cdot \sigma(P^i))$$

- Testy dla wartości numerycznych są binarne z wartością minimalizującą SDR,
- Atrybuty nominalne obsługiwane są zgodnie ze sposobem opisanym wcześniej dla regresji

Inne rozszerzenia algorytmu

- Brakujące wartości atrybutów obsługiwane są poprzez zastępowanie ich wartością średnią lub poprzez „zgadywanie” wartości atrybutu na podstawie wartości atrybutu najbardziej skorelowanego,
- „Wygładzanie” osiąga się poprzez przechowywanie wartości w każdym węźle drzewa (nie tylko w liściach) oraz poprzez uśrednianie

Drzewa predykcji numerycznej:

1. Zadanie: predykcja numeryczna
2. Struktura modelu: *drzewo regresji* lub *drzewo modelu*
3. Funkcja oceny jakości: minimalizacja odchylenia standardowego
4. Metody przeszukiwania: zachłanna, divide-and-conquer
5. Dodatkowe założenia:

Obsługa atrybutów nominalnych poprzez zamianę ich na serię atrybutów numerycznych

Obsługa wartości brakujących poprzez dobór atrybutu najbardziej skorelowanego

Przycinanie metodą walidacji krzyżowej