

Eksploracja danych

EKSPLORACYJNA ANALIZA DANYCH (EDA)

Wojciech Waloszek

wowal@eti.pg.edu.pl

Teresa Zawadzka

tegra@eti.pg.edu.pl

Katedra Inżynierii Oprogramowania

Wydział Elektroniki, Telekomunikacji i Informatyki

Politechnika Gdańska



EDA — *exploratory data analysis*


EDA to zestaw interaktywnych i wizualnych technik analizy zbioru danych bez bardziej precyzyjnego wskazania celu eksploracji.

EDA to także bardzo ważny element etapu wstępnej analizy danych.

EDA pozwala na:

- zgłębienie zbioru danych,
- sprawdzenie zależności między atrybutami,
- identyfikację nietypowych przykładów bądź podzbiorów przykładów,
- opracowanie wstępnych wniosków dotyczących prawidłowości w zbiorze przykładów.

Proces eksploracji danych (*Cross Industry Standard Process for Data Mining*)



<http://www.crisp-dm.org>

Poznaj swoje dane!

Dane nie zawsze są tak eleganckie...


S.C.	D.O.R.	Wiek	Wykształcenie	Sam.	Z.K.
S	800	32	wyższe	tak	tak
S	1200	35	średnie	tak	tak
S	700	26	podstawowe	nie	nie
M	600	45	wyższe	nie	tak
M	650	38	średnie	tak	tak
S	900	28	wyższe	nie	nie
S	1100	65	średnie	tak	nie
M	500	22	średnie	nie	nie
S	800	43	podstawowe	tak	nie

Poznaj swoje dane!

Kod pocztowy	Dochód roczny (tys. zł)	Wiek	Stan cywilny	Płeć
80249	70	32	S	M
00245	50000	35	M	
J2S7K7	40	26	K	M
90120		0	Ż	K
8230	999	38		K

Wykres pudełkowy (*boxplot*)

- wykres skrzynkowy
- wykres ramka-wąsy




Wykres pudełkowy (2)

Wykres pudełkowy służy do przedstawienia podstawowych parametrów rozkładu wartości atrybutów numerycznych. Występuje w różnych odmianach i może być narysowany pionowo lub poziomo.

Składa się z *pudełka* i *wąsów* (*wibrys*):

- lewa (dolna) krawędź pudełka odpowiada pierwszemu a prawa (dolna) krawędź trzeciemu kwartylowi (Q_1 , Q_3); pudełko przecina odcinek – mediana
- wąsy pokazują rozrzut danych „poza pudełkiem”, najczęściej jest to najbardziej skrajna wartość mieszcząca się jeszcze w odległości $1,5 * (Q_3 - Q_1)$ od odpowiednio Q_1 i Q_3
- punkty mieszczące się „poza wąsami” oznaczane są osobno jako *oddalone*

Histogram



Histogram (2)


Histogram jest diagramem pokazującym licznosc przykladów o wartosci danego atrybutu zawartej w pewnej klasie.

Histogram pozwala na:

- przyblizenie kształtu rozkładu,
- identyfikację punktów oddalonych,
- identyfikację wartosci specjalnych.



„Poszarpany” kształt histogramu utrudnia czasem interpretację rozkładu.

Przybliżanie rozkładu za pomocą wygładzania



$$f(x) = \frac{1}{n \cdot h} \sum_{i=1}^n K \frac{x - x_i}{h}$$

Wykresy punktowe



Wykresy punktowe (2)

Wykresy punktowe pozwalają na wizualizację zależności pomiędzy parą zmiennych.


Wykresy punktowe pozwalają m.in. na:

- odkrywanie korelacji między parą zmiennych,
- identyfikację punktów oddalonych od ogólnego trendu.

Macierze wykresów punktowych pozwalają na badanie większych podzbiorów atrybutów.

Wykresy punktowe podatne są na zjawisko tzw. overprintingu.

Overprinting i wykresy konturowe



EDA – podsumowanie

EDA jest bardzo ważnym etapem procesu eksploracji danych, czasem nawet występującym samodzielnie. EDA jest także bardzo cennym elementem procesu wstępnej analizy danych pozwalającym na:

- lepsze poznanie zbioru przykładów, również poprzez wskazanie nietypowych wartości atrybutów, punktów tzw. oddalonych i anomalnych itp.,
- wyciągnięcie wstępnych, często bardzo interesujących z punktu widzenia klienta, wniosków na temat zależności pomiędzy wartościami poszczególnych zmiennych,
- opracowanie zbioru zaleceń co do sposobów przekształcenia i modelowania danych na dalszych etapach procesu eksploracji.