

# Eksploracja danych

## KLASYFIKACJA I REGRESJA cz. 2

***Wojciech Waloszek***

*wowal@eti.pg.gda.pl*

***Teresa Zawadzka***

*tegra@eti.pg.gda.pl*

*Katedra Inżynierii Oprogramowania*

*Wydział Elektroniki, Telekomunikacji i Informatyki*

*Politechnika Gdańska*



# Budowa reguł decyzyjnych

- Reguły decyzyjne są bardzo popularną formą wyrażania zasad klasyfikacji,
- Budowane są różnymi metodami, jedną z nich jest metoda oparta na podejściu separate-and-conquer

# Pokrycie i poprawność reguły

| S.C. | D.O.R. | Wiek | Wykształcenie | Sam. | Z.K. |
|------|--------|------|---------------|------|------|
| S    | 800    | 32   | wyższe        | tak  | tak  |
| S    | 1200   | 35   | średnie       | tak  | tak  |
| S    | 700    | 26   | podstawowe    | nie  | nie  |
| M    | 600    | 45   | wyższe        | nie  | tak  |
| M    | 650    | 38   | średnie       | tak  | tak  |
| S    | 900    | 28   | wyższe        | nie  | nie  |
| S    | 1100   | 65   | średnie       | tak  | nie  |
| M    | 500    | 22   | średnie       | nie  | nie  |
| S    | 800    | 43   | podstawowe    | tak  | nie  |

**if Sam.=nie then Z.K.=nie**

# Pokrycie i poprawność reguły

| S.C. | D.O.R. | Wiek | Wykształcenie | Sam. | Z.K. |
|------|--------|------|---------------|------|------|
| S    | 800    | 32   | wyższe        | tak  | tak  |
| S    | 1200   | 35   | średnie       | tak  | tak  |
| S    | 700    | 26   | podstawowe    | nie  | nie  |
| M    | 600    | 45   | wyższe        | nie  | tak  |
| M    | 650    | 38   | średnie       | tak  | tak  |
| S    | 900    | 28   | wyższe        | nie  | nie  |
| S    | 1100   | 65   | średnie       | tak  | nie  |
| M    | 500    | 22   | średnie       | nie  | nie  |
| S    | 800    | 43   | podstawowe    | tak  | nie  |

if Sam.=nie then Z.K.=nie

**Pokrycie:  $s = 4 / 9$**

**Poprawność:  $a = 3 / 4$**

## Pokrycie i poprawność reguły (2)

- Pokrycie (ang. *coverage*, *support*) to liczba przykładów, dla których zadziała reguła (które spełniają część testową reguły).
- Poprawność (ang. *accuracy*, *confidence*) to liczba przykładów poprawnie klasyfikowanych przez regułę.

# Budowa reguł


| S.C. | D.O.R. | Wiek | Wykształcenie | Sam. | Z.K. |
|------|--------|------|---------------|------|------|
| S    | 800    | 32   | wyższe        | tak  | tak  |
| S    | 1200   | 35   | średnie       | tak  | tak  |
| S    | 700    | 26   | podstawowe    | nie  | nie  |
| M    | 600    | 45   | wyższe        | nie  | tak  |
| M    | 650    | 38   | średnie       | tak  | tak  |
| S    | 900    | 28   | wyższe        | nie  | nie  |
| S    | 1100   | 65   | średnie       | tak  | nie  |
| M    | 500    | 22   | średnie       | nie  | nie  |
| S    | 800    | 43   | podstawowe    | tak  | nie  |

1. Mamy wyróżniony atrybut decyzyjny, wyznaczający *klasy*
2. Budujemy regułę pod kątem najlepszej poprawności i, w drugim rzędzie, największego pokrycia.
3. Rozpoczynamy od pustej reguły wyznaczając kolejne testy.

# Budowa reguły decyzyjnej

Do reguły pustej:

`if ? then Z.K.=?`



wstawiamy „na próbę” wszystkie możliwe testy proste (z rezultatem):

`S.C.=S`

`S.C.=M`

`Wykształcenie=podstawowe`

`Wykształcenie=średnie`

`Wykształcenie=wyższe`

`Sam.=tak`

`Sam.=nie`

# Budowa reguły decyzyjnej (2)

| S.C. | D.O.R. | Wiek | Wykształcenie | Sam. | Z.K. |
|------|--------|------|---------------|------|------|
| S    | 800    | 32   | wyższe        | tak  | tak  |
| S    | 1200   | 35   | średnie       | tak  | tak  |
| S    | 700    | 26   | podstawowe    | nie  | nie  |
| M    | 600    | 45   | wyższe        | nie  | tak  |
| M    | 650    | 38   | średnie       | tak  | tak  |
| S    | 900    | 28   | wyższe        | nie  | nie  |
| S    | 1100   | 65   | średnie       | tak  | nie  |
| M    | 500    | 22   | średnie       | nie  | nie  |
| S    | 800    | 43   | podstawowe    | tak  | nie  |

if S.C.=S then Z.K.=?

if S.C.=S then Z.K.=nie

**Pokrycie:  $s = 6$**

**Poprawność:  $a = 4 / 6$**

## Budowa reguły decyzyjnej (3)

Po zbadaniu wszystkich testów otrzymujemy:

|                          | a   | s |
|--------------------------|-----|---|
| S.C.=S                   | 4/6 | 6 |
| S.C.=M                   | 2/3 | 3 |
| Wykształcenie=podstawowe | 2/2 | 2 |
| Wykształcenie=średnie    | 2/4 | 4 |
| Wykształcenie=wyższe     | 2/3 | 3 |
| Sam.=tak                 | 3/5 | 5 |
| Sam.=nie                 | 3/4 | 4 |

Wybieramy test (i regułę), dla której osiągnięto największą poprawność

## Budowa reguły decyzyjnej (4)

- Ponieważ osiągnięta poprawność wynosi 100%, pierwsza reguła jest gotowa:

`if Wykształcenie=podstawowe then Z.K.=nie`

- Następne reguły budowane są analogicznie po zastosowaniu zasady separate-and-conquer

# Separate-and-conquer

| S.C. | D.O.R. | Wiek | Wykształcenie | Sam. | Z.K. |
|------|--------|------|---------------|------|------|
| S    | 800    | 32   | wyższe        | tak  | tak  |
| S    | 1200   | 35   | średnie       | tak  | tak  |
| S    | 700    | 26   | podstawowe    | nie  | nie  |
| M    | 600    | 45   | wyższe        | nie  | tak  |
| M    | 650    | 38   | średnie       | tak  | tak  |
| S    | 900    | 28   | wyższe        | nie  | nie  |
| S    | 1100   | 65   | średnie       | tak  | nie  |
| M    | 500    | 22   | średnie       | nie  | nie  |
| S    | 800    | 43   | podstawowe    | tak  | nie  |

1. W zbiorze przykładów wyróżniliśmy dwa pokrywane przez regułę
2. Usuwamy te przykłady z naszego zbioru trenującego, a dla pozostałej jego części stosujemy ponownie procedurę budowy najlepszej reguły

# Budowa kolejnych reguł

- Ponownie rozpoczynamy od reguły pustej, rozważając pozostałe testy:

**S.C.=S**

**S.C.=M**

**Wykształcenie=średnie**

**Wykształcenie=wyższe**

**Sam.=tak**

**Sam.=nie**

## Budowa kolejnych reguł (2)

Po zbadaniu wszystkich testów otrzymujemy:

|                       | a   | s |
|-----------------------|-----|---|
| S.C.=S                | 2/4 | 4 |
| S.C.=M                | 2/3 | 3 |
| Wykształcenie=średnie | 2/4 | 4 |
| Wykształcenie=wyższe  | 2/3 | 3 |
| Sam.=tak              | 3/4 | 4 |
| Sam.=nie              | 2/3 | 3 |

Wybieramy test o największej poprawności

## Budowa kolejnych reguł (3)

- Ponieważ osiągnięta poprawność wynosi 75%, regułę można jeszcze poprawić:

```
if Sam.=tak then Z.K.=tak
```

- Regułę możemy rozbudowywać, wybierając kolejne testy:

```
if Sam.=tak and ? then Z.K.=?
```

# Rozbudowa reguły

| S.C. | D.O.R. | Wiek | Wykształcenie | Sam. | Z.K. |
|------|--------|------|---------------|------|------|
| S    | 800    | 32   | wyższe        | tak  | tak  |
| S    | 1200   | 35   | średnie       | tak  | tak  |
| S    | 700    | 26   | podstawowe    | nie  | nie  |
| M    | 600    | 45   | wyższe        | nie  | tak  |
| M    | 650    | 38   | średnie       | tak  | tak  |
| S    | 900    | 28   | wyższe        | nie  | nie  |
| S    | 1100   | 65   | średnie       | tak  | nie  |
| M    | 500    | 22   | średnie       | nie  | nie  |
| S    | 800    | 43   | podstawowe    | tak  | nie  |

**Przy rozbudowywaniu reguły ograniczmy się do rozpatrywania przykładów pokrywanych przez pierwszy test niepokrywanych przez poprzednie reguły.**

**if Sam.=tak and ? then Z.K.=?**

# Rozbudowa reguły

| S.C. | D.O.R. | Wiek | Wykształcenie | Sam. | Z.K. |
|------|--------|------|---------------|------|------|
| S    | 800    | 32   | wyższe        | tak  | tak  |
| S    | 1200   | 35   | średnie       | tak  | tak  |
| S    | 700    | 26   | podstawowe    | nie  | nie  |
| M    | 600    | 45   | wyższe        | nie  | tak  |
| M    | 650    | 38   | średnie       | tak  | tak  |
| S    | 900    | 28   | wyższe        | nie  | nie  |
| S    | 1100   | 65   | średnie       | tak  | nie  |
| M    | 500    | 22   | średnie       | nie  | nie  |
| S    | 800    | 43   | podstawowe    | tak  | nie  |

**Przy rozbudowywaniu reguły ograniczmy się do rozpatrywania przykładów pokrywanych przez pierwszy test niepokrywanych przez poprzednie reguły.**

**if Sam.=tak and ? then Z.K.=?**

## Rozbudowa reguły (2)

- W miejsce „?” moglibyśmy wstawić jeden z testów wartości atrybutów nominalnych:

**S.C.=S**

**S.C.=M**

**Wykształcenie=średnie**

**Wykształcenie=wyższe**

- Pokrycie i poprawność tak wygenerowanej reguły sprawdzamy analogicznie jak poprzednio

# Rozbudowa reguły (3)

| S.C. | D.O.R. | Wiek | Wykształcenie | Sam. | Z.K. |
|------|--------|------|---------------|------|------|
| S    | 800    | 32   | wyższe        | tak  | tak  |
| S    | 1200   | 35   | średnie       | tak  | tak  |
| S    | 700    | 26   | podstawowe    | nie  | nie  |
| M    | 600    | 45   | wyższe        | nie  | tak  |
| M    | 650    | 38   | średnie       | tak  | tak  |
| S    | 900    | 28   | wyższe        | nie  | nie  |
| S    | 1100   | 65   | średnie       | tak  | nie  |
| M    | 500    | 22   | średnie       | nie  | nie  |
| S    | 800    | 43   | podstawowe    | tak  | nie  |

if Sam.=tak and S.C.=S then Z.K.=?

Pokrycie:  $s = 3$

Poprawność:  $a = 2 / 3$

## Rozbudowa reguły (4)

Po zbadaniu testów otrzymujemy:

|                       | a   | s |
|-----------------------|-----|---|
| S.C.=S                | 2/3 | 3 |
| S.C.=M                | 1/1 | 1 |
| Wykształcenie=średnie | 2/3 | 3 |
| Wykształcenie=wyższe  | 1/1 | 1 |

Moglibyśmy na tym poprzestać, wybierając test o największej poprawności, ale tutaj włączymy do rozważań atrybuty numeryczne

# Obsługa atrybutów numerycznych

Testy dla atrybutów numerycznych mogą być wyznaczane na różne sposoby – również omówioną metodą podziału binarnego minimalizującego entropię:

# Obsługa atrybutów numerycznych

Testy dla atrybutów numerycznych mogą być wyznaczane na różne sposoby – również omówioną metodą podziału binarnego minimalizującego entropię:

|       |     |     |     |     |
|-------|-----|-----|-----|-----|
| Wiek: | 32  | 35  | 38  | 65  |
| Z.K.: | tak | tak | tak | nie |

Co daje nam dwa dodatkowe testy do rozpatrzenia:

**Wiek $\leq$ 45**

**Wiek $>$ 45**

## Rola pokrycia

- Tym razem otrzymujemy wynik:

|                       | a   | s |
|-----------------------|-----|---|
| S.C.=S                | 2/3 | 3 |
| S.C.=M                | 1/1 | 1 |
| Wykształcenie=średnie | 2/3 | 3 |
| Wykształcenie=wyższe  | 1/1 | 1 |
| Wiek≤45               | 3/3 | 3 |
| Wiek>45               | 1/1 | 1 |
| D.O.R.≤900            | 2/2 | 2 |
| D.O.R.>900            | 1/2 | 2 |

Wybieramy test o największej poprawności  
i największym pokryciu

## Kolejne kroki

- Ponieważ osiągnięta poprawność wynosi 100%, druga reguła jest gotowa:

**if Sam.=tak and Wiek<=45 then Z.K.=tak**

- Cały proces jest powtarzany (następna iteracja) po kolejnym zastosowaniu zasady separate-and-conquer

## Kolejne kroki (2)

| S.C. | D.O.R. | Wiek | Wykształcenie | Sam. | Z.K. |
|------|--------|------|---------------|------|------|
| S    | 800    | 32   | wyższe        | tak  | tak  |
| S    | 1200   | 35   | średnie       | tak  | tak  |
| S    | 700    | 26   | podstawowe    | nie  | nie  |
| M    | 600    | 45   | wyższe        | nie  | tak  |
| M    | 650    | 38   | średnie       | tak  | tak  |
| S    | 900    | 28   | wyższe        | nie  | nie  |
| S    | 1100   | 65   | średnie       | tak  | nie  |
| M    | 500    | 22   | średnie       | nie  | nie  |
| S    | 800    | 43   | podstawowe    | tak  | nie  |

if Wykształcenie=podstawowe then Z.K.=nie

if Sam.=tak and Wiek<=45 then Z.K.=tak

if S.C.=S then Z.K.=nie

if D.O.R.<=500 then Z.K.=nie else Z.K.=tak

# Budowa reguł – komentarz

- Zastosowanie zasady separate-and-conquer sprawia, że wygenerowane reguły muszą być rozpatrywane łącznie i w kolejności,
- Metoda w sposób naturalny radzi sobie z brakującymi wartościami atrybutów (są one „spychane” do następnej iteracji),
- Metodę można rozszerzyć o pewne mechanizmy uogólniające, przycinające reguły według pewnych zależności statystycznych

# Budowa reguł – komentarz

- Zastosowanie zasady separate-and-conquer sprawia, że wygenerowane reguły muszą być rozpatrywane łącznie i w kolejności,
- Metoda w sposób naturalny radzi sobie z brakującymi wartościami atrybutów (są one „spychane” do następnej iteracji),
- Metodę można rozszerzyć o pewne mechanizmy uogólniające, przycinające reguły według pewnych zależności statystycznych

# Budowa reguł – komentarz

- Zastosowanie zasady separate-and-conquer sprawia, że wygenerowane reguły muszą być rozpatrywane łącznie i w kolejności,
- Metoda w sposób naturalny radzi sobie z brakującymi wartościami atrybutów (są one „spychane” do następnej iteracji),
- Metodę można rozszerzyć o pewne mechanizmy uogólniające, przycinające reguły według pewnych zależności statystycznych

# Budowa reguł – podsumowanie

## Algorytm budowy reguł decyzyjnych:

1. Zadanie: predykcja (klasyfikacja)
2. Struktura modelu: reguły rozpatrywane w kolejności
3. Funkcja oceny jakości: poprawność (1) i pokrycie (2)
4. Metody przeszukiwania: zachłanna, separate-and-conquer
5. Dodatkowe założenia:  
Obsługa atrybutów numerycznych metodą podziału binarnego minimalizującego entropię

# Budowa reguł – podsumowanie

## Algorytm budowy reguł decyzyjnych:

1. Zadanie: predykcja (klasyfikacja)
2. Struktura modelu: reguły rozpatrywane w kolejności
3. Funkcja oceny jakości: poprawność (1) i pokrycie (2)
4. Metody przeszukiwania: zachłanna, separate-and-conquer
5. Dodatkowe założenia:  
Obsługa atrybutów numerycznych metodą podziału binarnego minimalizującego entropię