

Eksploracja danych

OCENA WYJŚCIA cz. 1

Wojciech Waloszek

wowal@eti.pg.gda.pl

Teresa Zawadzka

tegra@eti.pg.gda.pl

Katedra Inżynierii Oprogramowania



Wydział Elektroniki, Telekomunikacji i Informatyki

Politechnika Gdańska




Tworzenie modelu danych

Proces eksploracji danych można rozumieć jako dopasowywanie modelu do danych



Proces eksploracji danych (*Cross Industry Standard Process for Data Mining*)



<http://www.crisp-dm.org>

Ocena wyjścia


- Omówione metody budują klasyfikatory, które osiągają bardzo dobre wyniki na *zbiorze uczącym*,
- Często okazuje się, że klasyfikator osiągający dobry wynik na zbiorze uczącym ma bardzo słabe właściwości predykcyjne,
- Zjawisko to nazywamy *błędem nadmiernego dopasowania*.

Błąd nadmiernego dopasowania

Nazwisko	Wiek	Wykształcenie	Sam.	Z.K.
Abacki	32	wyższe	tak	tak
Babacka	35	średnie	tak	tak
Cabacki	26	podstawowe	nie	nie
Dabacka	45	wyższe	nie	tak
Ebacki	38	średnie	tak	tak
Fabacki	28	wyższe	nie	nie
Gabacka	65	średnie	tak	nie
Habacka	22	średnie	nie	nie
Ibacki	43	podstawowe	tak	nie


```
if Nazwisko=Abacki then Z.K.=tak  
if Nazwisko=Babacka then Z.K.=tak  
if Nazwisko=Cabacki then Z.K.=nie  
...
```

Zbiór trenujący i testujący




Standardowe podejście do oceny klasyfikatora to podział zbioru przykładów (zbioru uczącego) na *trenujący* i *testujący*

Zbiór trenujący i testujący(2)




Klasyfikator budujemy na podstawie zbioru trenującego, a następnie badamy jego skuteczność na zbiorze testującym

Zbiór trenujący i testujący(3)




Podejście to najczęściej stosujemy tylko do oceny siły predykcyjnej, a właściwy klasyfikator budujemy używając całego zbioru przykładów.

Stratyfikacja




Przy wyborze zbioru
trenującego istnieje
niebezpieczeństwo
nierównomiernej
reprezentacji niektórych
klas,
Temu efektowi zapobiega
stratyfikacja.

Efekt stratyfikacji




Stratyfikacja polega na dokonywaniu takich podziałów zbioru przykładów, aby klasy były równomiernie reprezentowane w każdej jego części

Podział zbioru na n części




Pomimo dokonania stratyfikacji, wciąż możemy mieć wątpliwości co do wyboru zbioru testującego,
Odpowiedzią może być podział zbioru na n części

Podział zbioru na n części (2)




Przy zastosowaniu tego
podejścia proces uczenia
powtarzamy n razy,
Przy każdym powtórzeniu
jedną część zbioru (tu: $\frac{1}{4}$)
przyjmujemy za zbiór
testujący, resztę jako
trenujący (tu: $\frac{3}{4}$)

Podział zbioru na n części (2)




Przy zastosowaniu tego
podejścia proces uczenia
powtarzamy n razy,
Przy każdym powtórzeniu
jedną część zbioru (tu: $\frac{1}{4}$)
przyjmujemy za zbiór
testujący, resztę jako
trenujący (tu: $\frac{3}{4}$)

Podział zbioru na n części (2)




Przy zastosowaniu tego
podejścia proces uczenia
powtarzamy n razy,
Przy każdym powtórzeniu
jedną część zbioru (tu: $\frac{1}{4}$)
przyjmujemy za zbiór
testujący, resztę jako
trenujący (tu: $\frac{3}{4}$)

Podział zbioru na n części (2)




Przy zastosowaniu tego
podejścia proces uczenia
powtarzamy n razy,
Przy każdym powtórzeniu
jedną część zbioru (tu: $\frac{1}{4}$)
przyjmujemy za zbiór
testujący, resztę jako
trenujący (tu: $\frac{3}{4}$)

m-krotne dokonanie podziału



Można jednak wskazać
same granice podziału
jako potencjalne źródło
błędów,
Rozwiązanie może być
m-krotne powtórzenie
podziału na *n* części,
Proces uczenia
powtarzamy wówczas
 $m \cdot n$ razy

m-krotne dokonanie podziału



Można jednak wskazać
same granice podziału
jako potencjalne źródło
błędów,
Rozwiązanie może być
m-krotne powtórzenie
podziału na *n* części,
Proces uczenia
powtarzamy wówczas
 $m \cdot n$ razy

Ocena jakości klasyfikatora

Walidacja krzyżowa

Walidacja skrośna

Kroswalidacja

- Opisana metoda jest jedną z najpopularniejszych metod oceny klasyfikatorów:

m n-fold cross-validation with stratification

- Najczęściej przyjmujemy $m=n=10$ otrzymując:

10 10-fold cross-validation with stratification

Ocena jakości klasyfikatora

Walidacja krzyżowa

Walidacja skrośna

Kroswalidacja

- Opisana metoda jest jedną z najpopularniejszych metod oceny klasyfikatorów:

m n-fold cross-validation with stratification

- Najczęściej przyjmujemy $m=n=10$ otrzymując:

10 10-fold cross-validation with stratification