

Algorytm SPADE - częste sekwencje

25 marca 2017

Zbiór zaki - pakiet arulesSequence

Znajdowanie częstych sekwencji w pierwszej kolejności oprzemy na zbiorze **zaki** z pakietu *arulesSequences*.

```
install.packages("arules")
install.packages("arulesSequences")
install.packages("Matrix")
# Zainstaluj Rtools z: https://cran.r-project.org/bin/windows/Rtools/

library(arules)
library(arulesSequences)

# Znajdź lokalizację pakietu arulesSequence
find.package("arulesSequences")

## [1] "C:/Users/mliksz/Documents/R/win-library/3.3/arulesSequences"
# używając funkcji system, wyświetl dane przy pomocy komendy bashowej cat
system("cat C:/Users/mliksz/Documents/R/win-library/3.3/arulesSequences/misc/zaki.txt")
# powyższa komenda jest w zupełności wystarczająca, jednakże wynik ma inne formatowanie, które
# nie mogło być wygenerowane w pdf, dlatego poniżej zastosowano obejście
cmd <- system("cat C:/Users/mliksz/Documents/R/win-library/3.3/arulesSequences/misc/zaki.txt",
              intern = TRUE)
cat(cmd, sep = '\n')

## 1 10 2 C D
## 1 15 3 A B C
## 1 20 3 A B F
## 1 25 4 A C D F
## 2 15 3 A B F
## 2 20 1 E
## 3 10 3 A B F
## 4 10 3 D G H
## 4 20 2 B F
## 4 25 3 A G H
```

Każda linia w powyższym zbiorze oznacza jedno zdarzenie. Pierwsza kolumna to identyfikator sekwencji, do której należy dane zdarzenie. Druga to znacznik czasu (ang. *timestamp*), oznaczająca moment w czasie, w którym pojawiło się zdarzenie. Trzecia kolumna to liczba elementów w tym zdarzeniu, po niej pojawia się lista tych elementów - każdy z nich to jedna kolumna.

```
# wczytanie danych
data_zaki <- read_baskets(con = system.file("misc", "zaki.txt", package = "arulesSequences"),
                        info = c("sequenceID", "eventID", "SIZE"))
```

```
as(data_zaki, "data.frame") # bardzo dużo wyników - pominięto wyświetlanie w tym dokumencie
```

Algorytm SPADE - zaki

```
spade_zaki <- cspade(data_zaki, parameter = list(support = 0.04),  
                    control = list(verbose = TRUE))
```

```
##  
## parameter specification:  
## support : 0.04  
## maxsize : 10  
## maxlen : 10  
##  
## algorithmic control:  
## bfstype : FALSE  
## verbose : TRUE  
## summary : FALSE  
## tidLists : FALSE  
##  
## preprocessing ... 1 partition(s), 0 MB [0.08s]  
## mining transactions ... 0.11 MB [0.09s]  
## reading sequences ... [0.32s]  
##  
## total elapsed time: 0.49s  
summary(spade_zaki)  
  
## set of 3917 sequences with  
##  
## most frequent items:  
##      A      C      B      F      D (Other)  
##    3370   3234   2956   2942   2930    388  
##  
## most frequent elements:  
##      {C}      {D}      {C,D}      {A}      {B} (Other)  
##    1356    1148    1124    1047    929    7290  
##  
## element (sequence) size distribution:  
## sizes  
##    1    2    3    4  
##   31  328 1353 2205  
##  
## sequence length distribution:  
## lengths  
##    1  2  3  4  5  6  7  8  9 10 11 12  
##    8 57 191 444 743 897 784 494 220 66 12 1  
##  
## summary of quality measures:  
##      support  
##    Min.   :0.2500  
##   1st Qu.:0.2500  
##   Median :0.2500  
##    Mean   :0.2519
```

```
## 3rd Qu.:0.2500
## Max. :1.0000
##
## includes transaction ID lists: FALSE
##
## mining info:
##      data ntransactions nsequences support
## data_zaki          10          4    0.04
as(spade_zaki, "data.frame") # bardzo dużo wyników - pominięto wyświetlanie w tym dokumencie
```

Zbiór Delicious

Tym razem zmierzmy się z zagadnieniem rekomendacji używając tagów. Tagi w tym przypadku to słowa kluczowe przypisane przez użytkownika do elementów zawartych na danej stronie internetowej. Ten system rekomendacji ma sugerować użytkownikom nowe tagi, które powinni użyć w celu poprawienia jakości wyników, które otrzymają np. przy pomocy wyszukiwarki Google'a. Zbiór danych, które wykorzystamy został wygenerowany na podstawie serwisu Delicious (<https://del.icio.us>). Zawiera on zakładki wszystkich użytkowników serwisu z października 2009. Każda zakładka składa się z użytkownika, adresu URL zakładki oraz zbioru tagów, użytych do opisu zawartości adresu URL.

Przykład: gmenezes http://www.traderslog.com/forum/* 5 education investment forex CFD trading
 Użytkownik **gmenezes** oznaczył zawartość adresu URL http://www.traderslog.com/forum/* 5 tagami: education, investment, forex, CFD, trading
 Istotną informacją jest to, że zbiór jest wygenerowany w oparciu o linię czasu, a więc oznaczenia adresów URL są w porządku czasowym -> możemy otrzymać sekwencje zakładek dla konkretnych użytkowników.

Algorytm SPADE - delicious

```
# pobierzcie delicious_sequence.txt z moodle i wrzućcie np. na pulpit, następnie ustawcie
# ścieżkę do tego pliku używając poniższej funkcji setwd
setwd("C:/Users/mliks/Desktop/WSB/Zajęcia 2/SPADE")

data_delicious <- read_baskets(con = "delicious_sequence.txt",
                              info = c("sequenceID", "eventID", "SIZE"))
summary(data_delicious)
```

```
## transactions as itemMatrix in sparse format with
## 7559 rows (elements/itemsets/transactions) and
## 7462 columns (items) and a density of 0.0004502772
##
## most frequent items:
##      design      tools      blog  webdesign inspiration  (Other)
##      469        301      233      229        220      23946
##
## element (itemset/transaction) length distribution:
## sizes
##      1      2      3      4      5      6      7      8      9     10     11     12     13     14     15
## 2283 1432 1172  826  560  342  230  273  171  100   60   34   25   15    4
##      16     17     18     19     20
##      5      5      7      8      7
##
##      Min. 1st Qu.  Median      Mean 3rd Qu.      Max.
```

```
##      1.00      1.00      3.00      3.36      4.00      20.00
```

```
##
```

```
## includes extended item information - examples:
```

```
##   labels
```

```
## 1      -
```

```
## 2     -5K
```

```
## 3     -ECG
```

```
##
```

```
## includes extended transaction information - examples:
```

```
##   sequenceID eventID SIZE
```

```
## 1           1         1   2
```

```
## 2           2         1   5
```

```
## 3           3         1   3
```

```
spade_delicious <- cspade(data_delicious, parameter = list(support = 0.1),  
                          control = list(verbose = TRUE))
```

```
##
```

```
## parameter specification:
```

```
## support : 0.1
```

```
## maxsize : 10
```

```
## maxlen  : 10
```

```
##
```

```
## algorithmic control:
```

```
## bfstype  : FALSE
```

```
## verbose  : TRUE
```

```
## summary  : FALSE
```

```
## tidLists : FALSE
```

```
##
```

```
## preprocessing ... 1 partition(s), 0.18 MB [0.05s]
```

```
## mining transactions ... 0 MB [0s]
```

```
## reading sequences ... [0.02s]
```

```
##
```

```
## total elapsed time: 0.07s
```

```
summary(spade_delicious)
```

```
## set of 0 sequences with
```

```
##
```

```
## most frequent items:
```

```
## integer(0)
```

```
##
```

```
## most frequent elements:
```

```
## integer(0)
```

```
##
```

```
## element (sequence) size distribution:
```

```
## < table of extent 0 >
```

```
##
```

```
## sequence length distribution:
```

```
## < table of extent 0 >
```

```
##
```

```
## summary of quality measures:
```

```
## < table of extent 0 >
```

```
##
```

```
## includes transaction ID lists: FALSE
```

```
##
## mining info:
##      data ntransactions nsequences support
## data_delicious      7559      4705      0.1

spade_delicious <- cspade(data_delicious, parameter = list(support = 0.002),
                          control = list(verbose = TRUE))

##
## parameter specification:
## support : 0.002
## maxsize :    10
## maxlen  :    10
##
## algorithmic control:
## bfstype : FALSE
## verbose  : TRUE
## summary  : FALSE
## tidLists : FALSE
##
## preprocessing ... 1 partition(s), 0.31 MB [0.06s]
## mining transactions ... 0.01 MB [0.06s]
## reading sequences ... [0.03s]
##
## total elapsed time: 0.15s

summary(spade_delicious)

## set of 720 sequences with
##
## most frequent items:
##      design  webdesign      tools inspiration      web      (Other)
##        125       63        58         39        35        812
##
## most frequent elements:
##      {design}      {tools} {webdesign} {inspiration}      {web}
##         45         25        17         14         11
##      (Other)
##        700
##
## element (sequence) size distribution:
## sizes
##   1  2  3  4
## 596 117  6  1
##
## sequence length distribution:
## lengths
##   1  2  3  4
## 321 330 63  6
##
## summary of quality measures:
##      support
## Min.      :0.002125
## 1st Qu.:0.002338
## Median :0.002976
```

```
## Mean      :0.004967
## 3rd Qu.   :0.004676
## Max.      :0.075027
##
## includes transaction ID lists: FALSE
##
## mining info:
##           data ntransactions nsequences support
## data_delicious      7559      4705    0.002
as(spade_delicious, "data.frame") # bardzo dużo wyników - pominięto wyświetlanie w tym dokumencie
```

Zadanie

Stwórz ramkę danych (analogiczną do zbioru zaki), a następnie wykonaj na niej (ze zrozumieniem) powyższe polecenia.